
Introduction To Data Analysis
데이터분석입문
Lecture 25. NumPy와 matplotlib 활용
인공지능소프트웨어학과 강환수 교수

학습개요

- 자료형 np.ndarray를 생성하는 함수 np.array()
- 돗수분포표 hist()에서 매개변수 bins
- 난수 발생 np.random.choice() np.random.rand(), np.random.randint()
- 논리 mask 생성과 활용

학습목표

- 함수 np.array()로 다양한 차수의 자료형 np.ndarray를 생성할 수 있다.
- 함수 plt.hist()에서 매개변수 bins를 구간으로 지정하는 의미를 알고 활용할 수 있다.
- 지정한 수 중에서 난수를 선택하는 np.random.choice()를 활용할 수 있다.
- 난수 발생 np.random.rand()와 np.random.randint()를 활용할 수 있다.

LESSON 01

numpy array 생성 및 활용

matplotlib.pyplot.hist

돗수분포표의 구간에도 ndarray나 리스트 사용 가능

- matplotlib.pyplot.hist(x, bins=None, range=None, density=False, weights=None, cumulative=False, bottom=None, histtype='bar', align='mid', orientation='vertical', rwidth=None, log=False, color=None, label=None, stacked=False, *, data=None, **kwargs)

hist()

2번째 매개변수

- bins int 또는 시퀀스 또는 str, 기본값: (기본값: 10)
  - rcParams["hist.bins"]=2 로 실행시간에 조정 가능
- bins가 정수인 경우 범위 내 동일한 너비의 bin 수를 정의
- bins가 시퀀스인 경우 첫 번째 bin의 왼쪽 가장자리와
  마지막 bin의 오른쪽 가장자리를 포함하여 bin 구간의 시퀀스를 정의
  - 저장소의 간격이 동일하지 않을 수 있으며,
    마지막(가장 오른쪽) 상자를 제외한 모든 상자는 반쯤 열려 있음(불포함)
- 즉, bins 가 다음과 같은 경우 : [1, 2, 3, 4]
  - 첫 번째 bin은 (1을 포함하지만 2는 제외)이고 두 번째 bin부터는 왼쪽 이상, 오른쪽 미만
  - 그러나 마지막 bin은 4를 포함
  - 즉, 각 구간은 [1, 2), [2, 3), [3, 4]를 의미

hist 속성 rwidth

- 기본이 1로 가로 폭이 100%
- 기본이 bins는 10

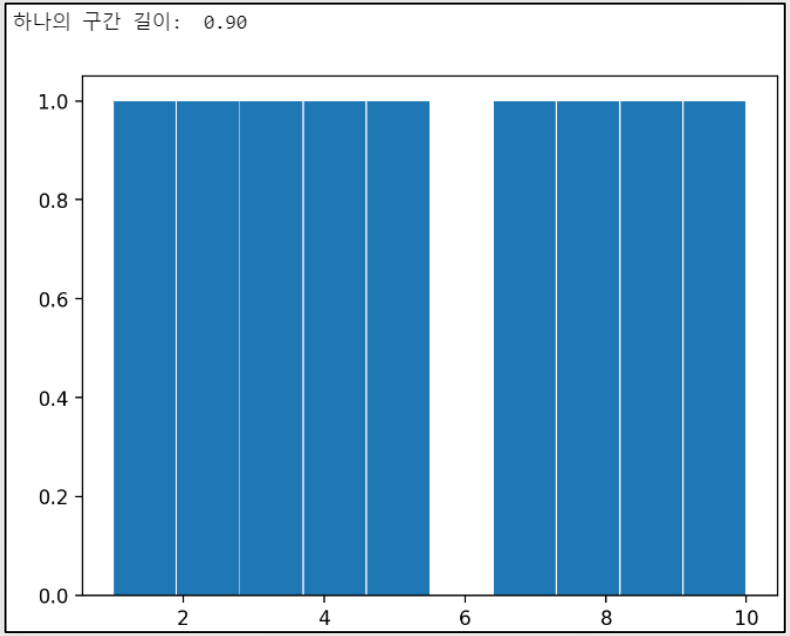


```python
import matplotlib.pyplot as plt

data = [1, 2, 3, 4, 5, 7, 8, 9, 10]

plt.hist(data, rwidth=.98) # 기본 bins=10

print(f'하나의 구간 길이: {( max(data)-min(data) ) / 10 : .2f}')
plt.show()
```

hist 속성 bins 수정

구간을 3개로 지정

```
import matplotlib.pyplot as plt

data = [10, 1, 2, 3, 4, 5, 7, 8, 9, 1]
plt.hist(data, bins=3, rwidth=.98)

print(f'하나의 구간 길이: {( max(data)-min(data) ) / 3 : .2f}')
plt.show()
```

✓ 7.9s

```
하나의 구간 길이:  3.00
```

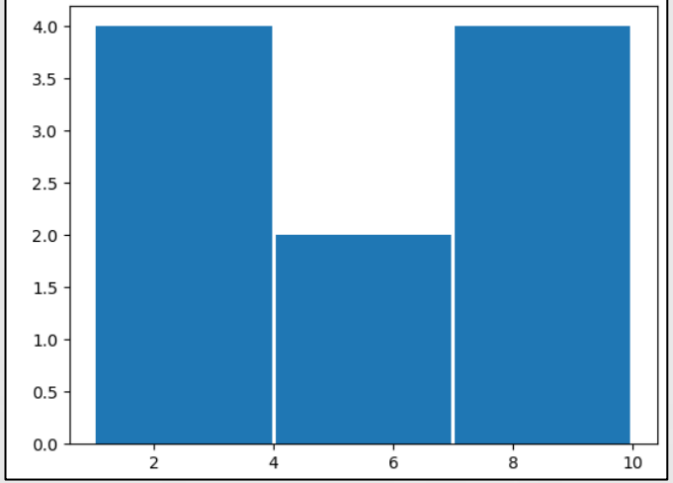

hist 속성 bins 수정

rcParams["hist.bins"]=2 지정

```
import matplotlib.pyplot as plt

data = [10, 1, 2, 3, 4, 5, 7, 8, 9, 1]

plt.rcParams["hist.bins"] = 2
plt.hist(data, rwidth=.98)

print(f'하나의 구간 길이: {( max(data)-min(data) ) / 2 : .2f}')
plt.show()
```

✓ 0.1s

```
하나의 구간 길이:  4.50
```

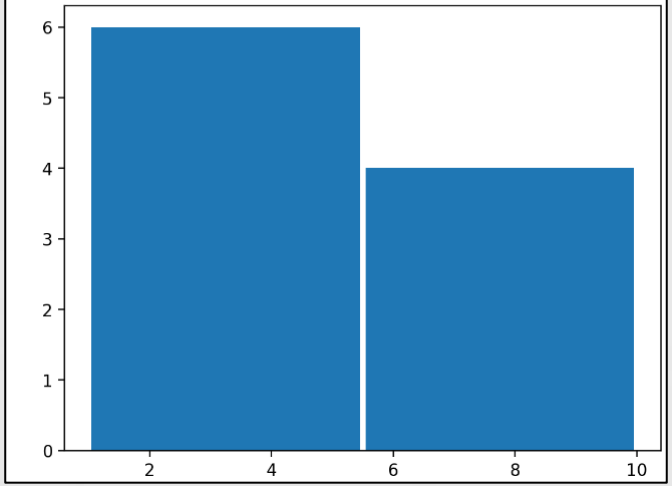

numpy 라이브러리를 활용하여 작성한 코드

```python
import matplotlib.pyplot as plt
import numpy as np

dice = np.random.choice(range(1, 7), 10)

plt.figure(figsize=(2, 1), dpi = 200)
plt.hist(dice, rwidth=.98, bins=[.5, 1.5, 2.5, 3.5, 4.5, 5.5, 6.5])
# plt.hist(dice, bins=np.arange(-.5, 7))
plt.xticks(range(1, 7))
plt.show()
```

✓ 0.0s Python

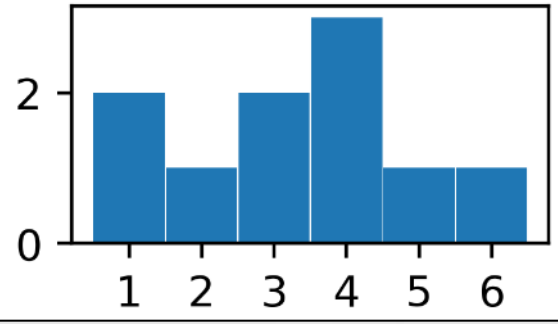

numpy 라이브러리를 활용할 경우 장점!
① 코드가 간결해짐
② 코드 실행 속도가 빠름

1부터 6까지 숫자를 랜덤으로 추출한 결과를 히스토그램으로 시각화하기

```python
import matplotlib.pyplot as plt
import numpy as np

dice = np.random.choice(range(1, 7), 1000000,
                        p = [0.15, 0.25, 0.3, 0.1, 0.1, 0.1])

plt.figure(figsize=(3, 2), dpi = 150)
plt.hist(dice, rwidth=.98, bins=np.arange(.5, 7))
# plt.hist(dice, rwidth=.98, bins=[.5, 1.5, 2.5, 3.5, 4.5, 5.5, 6.5])
plt.xticks(range(1, 7))
plt.show()
```

✓ 0.1s Python

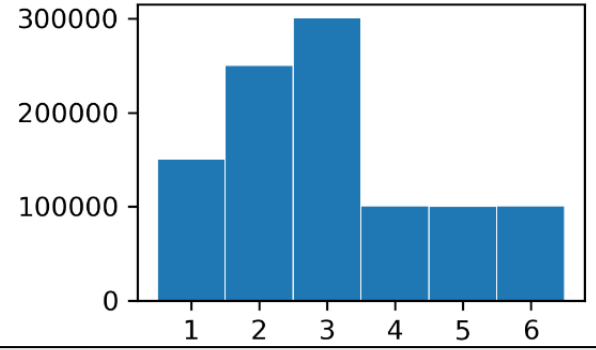

추출 시행 횟수를 늘리니,
p 속성에 설정했던 확률 값에 따라
각 숫자가 추출됨을 확인 할 수 있습니다.
(큰 수의 법칙)

numpy 라이브러리를 활용하여 작성한 코드

```
import matplotlib.pyplot as plt
import numpy as np

x = np.random.randint(10, 100, 200)
y = np.random.randint(10, 100, 200)
size = np.random.rand(200) * 100

plt.scatter(x, y, s = size, c = x, cmap = 'jet', alpha = 0.7)
plt.colorbar()
plt.show()
```

10이상 100미만의 정수 중 200개를 뽑는다.

0과 1사이의 실수 200개를 뽑는다.

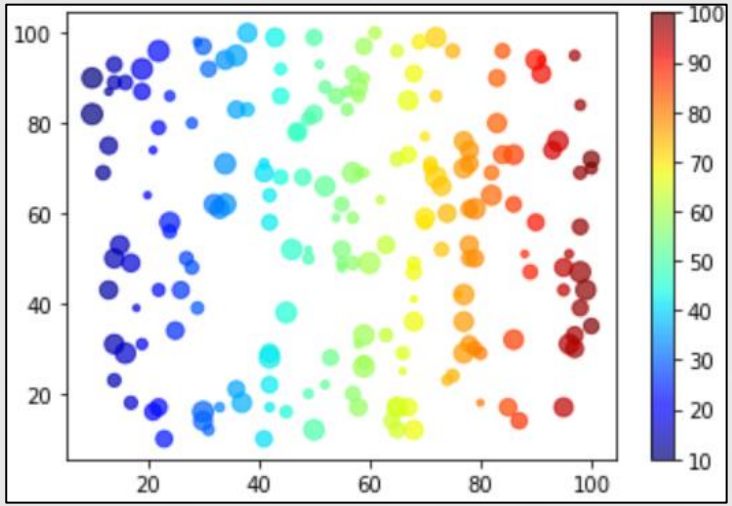

파이썬 리스트를 활용하여 작성한 코드

```
import matplotlib.pyplot as plt
import random

x = []
y = []
size = []

for i in range(200):
    x.append(random.randint(10, 100))
    y.append(random.randint(10, 100))
    size.append(random.randint(10, 100))

plt.scatter(x, y, s = size, c = x, cmap = 'jet', alpha = 0.7)
plt.colorbar()
plt.show()
```

10이상 100이하의 정수를 임의로 뽑는다.

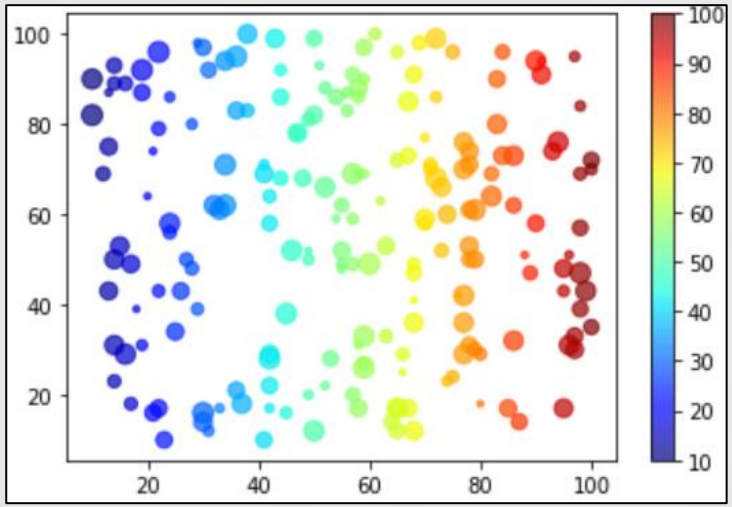

리스트로 ndarray(N-Dimensional Array) 만들기

```
import numpy as np

a = np.array([1, 2, 3, 4])
print(a)
```

```
[1 2 3 4]
```

numpy array의 인덱싱(Indexing), 슬라이싱(Slicing)

```python
import numpy as np

a = np.array([1, 2, 3, 4])
print(a[1], a[-1])
print(a[1:])
```

```
2 4
[2 3 4]
```

zeros( ), ones( ), eye( ) 함수로 numpy array 만들기

```
import numpy as np

a = np.zeros(10)
print(a)

b = np.ones(10)
print(b)

c = np.eye(3)
print(c)
```

3행 × 3열의 단위 행렬 생성

```
[0. 0. 0. 0. 0. 0. 0. 0. 0. 0.]
[1. 1. 1. 1. 1. 1. 1. 1. 1. 1.]
[[1. 0. 0.]
 [0. 1. 0.]
 [0. 0. 1.]]
```

연속된 숫자의 numpy array 만들기

```
import numpy as np

print(np.arange(3))
print(np.arange(3, 7))
print(np.arange(3, 7, 2))
```

```
[0 1 2]
[3 4 5 6]
[3 5]
```

연속된 실수의 numpy array 만들기

```python
import numpy as np

a = np.arange(1, 2, 0.1) # 1이상 2미만 구간에서 0.1 간격으로 실수 생성
b = np.linspace(1, 2, 11) #1부터 2까지 10개 구간으로 나눈 실수 생성
print(a)
print(b)
```

Python

```
[1.  1.1 1.2 1.3 1.4 1.5 1.6 1.7 1.8 1.9]
[1.  1.1 1.2 1.3 1.4 1.5 1.6 1.7 1.8 1.9 2. ]
```

연속된 실수의 numpy array 만들기

```
import numpy as np

a = np.arange(-np.pi, np.pi, np.pi/10)
b = np.linspace(-np.pi, np.pi, 20)
print(a)
print(b)
```

```
[-3.14159265 -2.82743339 -2.51327412 -2.19911486 -1.88495559 -1.57079633
 -1.25663706 -0.9424778  -0.62831853 -0.31415927  0.          0.31415927
  0.62831853  0.9424778   1.25663706  1.57079633  1.88495559  2.19911486
  2.51327412  2.82743339]
[-3.14159265 -2.81089869 -2.48020473 -2.14951076 -1.8188168  -1.48812284
 -1.15742887 -0.82673491 -0.49604095 -0.16534698  0.16534698  0.49604095
  0.82673491  1.15742887  1.48812284  1.8188168   2.14951076  2.48020473
  2.81089869  3.14159265]
```

numpy array에 값을 한꺼번에 더하기

```
import numpy as np

a = np.zeros(10) + 5
print(a)
```

```
[5. 5. 5. 5. 5. 5. 5. 5. 5. 5.]
```

numpy array에 함수 적용하기

```
import numpy as np

a = np.linspace(1, 2, 11)
print(np.sqrt(a))
```

```
[1.         1.04880885 1.09544512 1.14017543 1.18321596 1.22474487
 1.26491106 1.30384048 1.34164079 1.37840488 1.41421356]
```

numpy를 활용한 그래프 그리기

```
import numpy as np
import matplotlib.pyplot as plt

a = np.arange(-np.pi, np.pi, np.pi/100)

plt.plot(a, np.sin(a))
plt.show()
```

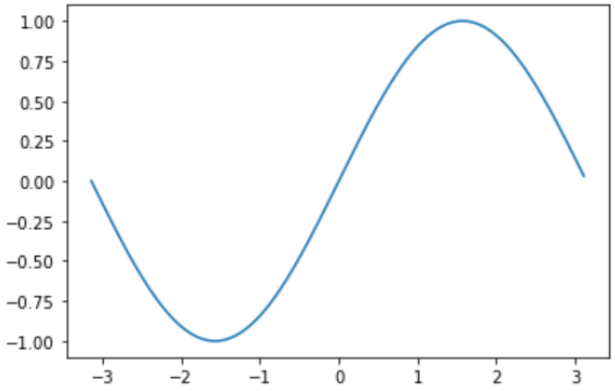

numpy를 활용한 다양한 그래프 그리기

```
import numpy as np
import matplotlib.pyplot as plt

a = np.arange(-np.pi, np.pi, np.pi/100)

plt.plot(a, np.sin(a), label='np.sin(a)')
plt.plot(a, np.cos(a), label='np.cos(a)')
plt.plot(a + np.pi / 2, np.sin(a), label='... np.sin(a)')
plt.legend()
plt.show()
```

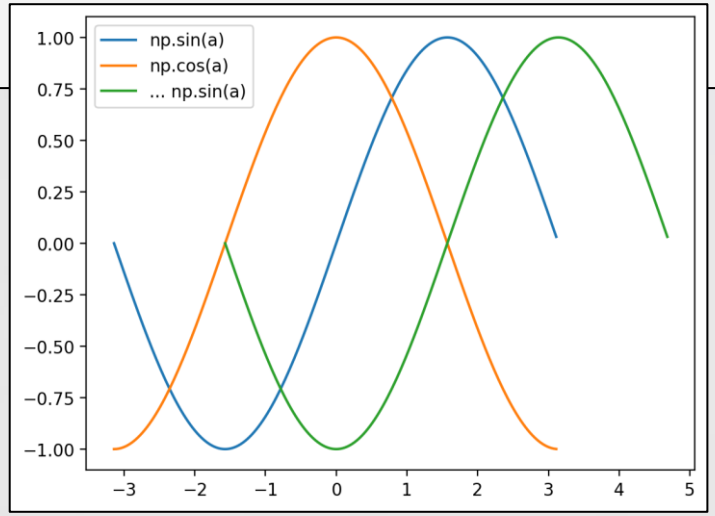

Numpy 활용의 장점

numpy 라이브러리를 활용하여 작성한 코드

```
import matplotlib.pyplot as plt
import numpy as np

t = np.arange(0., 5., 0.2)

plt.plot(t, t, 'r--', t, t**2, 'bs', t, t**3, 'g^')
plt.show()
```

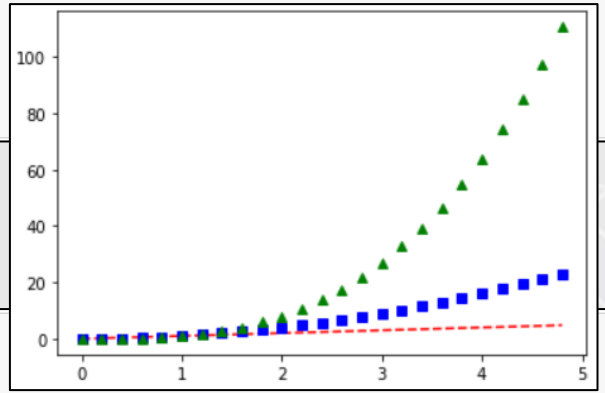

파이썬 리스트를 활용하여 작성한 코드

```
import matplotlib.pyplot as plt

a = []
b = []
c = []

for i in range(0, 50, 2):
    a.append(i / 10)
    b.append((i / 10) ** 2)
    c.append((i / 10) ** 3)

plt.plot(a, a, 'r--', a, b, 'bs', a, c, 'g^')
plt.show()
```

numpy 라이브러리를 활용할 경우
보다 적은 수의 코드로 그리고 간결하게
원하는 결과를 얻을 수 있습니다.

LESSON 02

numpy 논리 mask 활용

마스크(Mask) 만들고 적용하기

```python
import numpy as np

a = np.arange(-5, 5)    # 데이터 만들기
print(a)

print(a<0)              # 마스크 (Mask) 만들기
print(a[a<0])           # 마스크 적용하기
```

```
[-5 -4 -3 -2 -1  0  1  2  3  4]
[ True  True  True  True  True False False False False False]
[-5 -4 -3 -2 -1]
```

마스크(Mask) 연결해서 사용하기

```
import numpy as np

a = np.arange(-5, 5)
print(a)
```

[42] ✓ 0.0s Python

```
[-5 -4 -3 -2 -1  0  1  2  3  4]
```

```
mask1 = abs(a) > 3
print(mask1)
print(a[mask1])
```

[43] ✓ 0.0s Python

```
[ True  True False False False False False False False  True]
[-5 -4  4]
```

```
mask2 = (abs(a) % 2) == 0
print(mask2)
print(a[mask2])
```

[44] ✓ 0.0s Python

```
[False  True False  True False  True False  True False  True]
[-4 -2  0  2  4]
```

마스크(Mask) 연결해서 사용하기

```
[47]  print(mask1)
      print(mask2)

      print(mask1 + mask2)
      print(mask1 * mask2)
```

✓ 0.0s Python

```
[ True  True False False False False False False False  True]
[False  True False  True False  True False  True False  True]
[ True  True False  True False  True False  True False  True]
[False  True False False False False False False False  True]
```

```
[48]  print(a[mask1 + mask2]) # 둘 중 하나의 조건이라도 참일 경우
      print(a[mask1 * mask2]) # 두 가지 조건이 모두 참일 경우
```

✓ 0.0s Python

```
[-5 -4 -2  0  2  4]
[-4  4]
```

numpy 라이브러리를 사용하여 재미있는 산점도 표현

```python
import numpy as np
import matplotlib.pyplot as plt

x = np.random.randint(-100, 100, 1000)
y = np.random.randint(-100, 100, 1000)

mask1 = (abs(x) > 50)
mask2 = (abs(y) > 50)
x = x[mask1 + mask2]    # 둘 중 하나라도 참이면 포함
y = y[mask1 + mask2]

plt.scatter(x, y, c=x, cmap='jet', alpha=0.7)
plt.colorbar()
plt.show()
```

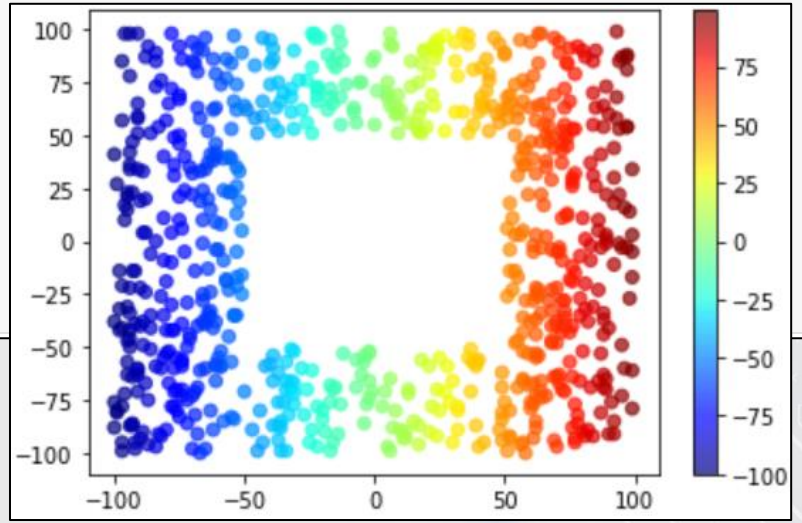

SUMMARY

학습정리

Matplotlib hist()

- matplotlib.pyplot.hist(x, bins=None, ···)

Numpy 난수 발생의 장점

- 여러 배열 생성 가능
- np.random.rand(d0, d1, d2, ···)
- np.random.randint(low, high=None, size=None, dtype=int)

주사위의 시행 횟수를 늘리면 결국 1/6 확률

- random.choice(a, size=None, replace=True, p=None)

```
dice = np.random.choice(range(1, 7), 1000000,
                        p = [0.15, 0.25, 0.3, 0.1, 0.1, 0.1])
```

마스크 생성과 활용

- Ndarray에 마스크를 적용해서 조건에 맞는 것을 선택 가능